

Klasifikasi Stroke Berdasarkan Kelainan Patologis dengan *Learning Vector Quantization*

Aji Seto Arifianto, Moechammad Sarosa, Onny Setyawati

Abstrak—Dampak yang ditimbulkan stroke diantaranya kelompoknya sebagian atau keseluruhan organ tubuh sampai kematian. Tingginya angka kematian akibat stroke disebabkan karena penanganan yang lambat. Diagnosis stroke harus dilakukan dengan cepat dan tepat agar segera mengetahui tipe klasifikasi patologinya termasuk dalam stroke *infark* atau *hemorrhagic* guna pemberian tindakan medis dan obat yang tepat pula. Prosedur wajib atau *Gold Standart Procedure* untuk klasifikasi stroke menggunakan *Computed Tomograph Scan* atau *Magnetic Resonance Imaging*, permasalahannya di Indonesia terkendala biaya yang mahal dan tidak semua rumah sakit memilikinya. Jika prosedur standar tidak dapat dilakukan maka diagnosis stroke dapat dilakukan melalui analisis terhadap data klinis pasien. Data klinis terdiri dari 32 fitur berisi tentang hasil pemeriksaan fisik, gejala yang dirasakan pasien, riwayat penyakit dan pemeriksaan laboratorium darah. Dalam penelitian ini diusulkan sebuah klasifikasi stroke secara komputerisasi menggunakan metode *Learning Vector Quantization* yang merupakan pengembangan dari *Kohonen Self-Organizing Map*, bersifat *supervised* dan *competitive learning*, struktur jaringannya *single layer-net*. Hasil dari penelitian ini tingkat akurasinya mencapai 96%. Uji diagnosis ditunjukkan dengan nilai *Area Under Curve* (AUC) sebesar 0,952 yang tergolong dalam kategori *excellent*.

Kata Kunci— Klasifikasi, Stroke, *Learning Vector Quantization*.

I. PENDAHULUAN

STROKE atau *Cerebrovascular disease* menurut *World Health Organization (WHO)* adalah “tanda-tanda klinis yang berkembang cepat akibat gangguan fungsi otak fokal atau global karena adanya sumbatan atau pecahnya pembuluh darah di otak dengan gejala-gejala yang berlangsung selama 24 jam atau lebih”. Klasifikasi penyakit stroke terdiri dari beberapa kategori, diantaranya: berdasarkan kelainan patologis, secara garis besar stroke dibagi dalam 2 tipe yaitu: *ischemic stroke* disebut juga *infark* atau *non-hemorrhagic* disebabkan oleh gumpalan atau penyumbatan dalam arteri yang menuju ke otak yang sebelumnya sudah mengalami proses aterosklerosis. *Ischemic stroke* terdiri dari tiga macam yaitu *embolic*

stroke, *thrombotic stroke* dan *hipoperfusi stroke*. Tipe kedua adalah *hemorrhagic stroke* merupakan kerusakan atau “ledakan” dari pembuluh darah di otak, perdarahan dapat disebabkan lamanya tekanan darah tinggi dan aneurisma otak. Ada dua jenis stroke *hemorrhagic*: *subarachnoid* dan *intracerebral*[1]. Akibat yang ditimbulkan oleh serangan stroke diantaranya kelemahan (lumpuh sebagian atau menyeluruh) secara mendadak, hilangnya sensasi berbicara, melihat, atau berjalan, hingga menyebabkan kematian. Di Indonesia berdasarkan riset kementerian kesehatan Indonesia tahun 2007 prevalensi penyakit tidak menular (PTM) khususnya stroke mencapai 8,3% urutan keempat. Penderita stroke yang meninggal diusia muda mulai memprihatinkan, direntang usia 45-54 tahun kematian karena stroke mencapai 15,9% diantara penyebabnya lambannya penanganan terhadap penderita[2].

Penanganan terhadap pasien stroke terutama pasien baru seharusnya dilakukan dengan cepat dan tepat. Kepastian penentuan tipepatologi stroke secara dini sangat penting untuk pemberian obat yang tepat guna mencegah dampak yang lebih fatal [3]. Prosedur utama diagnosis stroke (*Gold Standart*) menggunakan *Computed Tomography (CT) scan*, *Magnetic Resonance Imaging (MRI)* dan *Elektrokardiogram (EKG atau ECG)*. Kendala-kendala penerapan *gold standart* diatas karena ada pasien yang tidak memungkinkan untuk berpindah tempat, mahalnya biaya, tidak semua rumah sakit memiliki peralatan tersebut, memakan waktu lebih lama dan efek radiasi[4]. Diagnosis penyakit stroke dapat juga dilakukan melalui pemeriksaan klinis mulai dari menanyakan gejala yang dirasakan pasien, anamnesis atau pengambilan data riwayat penyakit pasien dan keluarganya, dan pemeriksaan neurologi[5].

Banyak berkembang berbagai penelitian tentang pemanfaatan teknologi komputer untuk membantu diagnosis penyakit dalam dunia kesehatan diantaranya untuk deteksi kanker payudara[6], klasifikasi untuk deteksi citra histologi kanker serviks [7], diagnosis penyakit melalui rekam aktivitas jantung[8]. Duen-Yian Yeh mengusulkan teknik klasifikasi untuk memperbaiki prediksi penyakit stroke dengan menggunakan 29 fitur dari pemeriksaan klinis dengan tiga metode klasifikasi. Hasilnya *Decision tree* mendapatkan hasil terbaik dengan Sensitivity 99,48% dan Accuracy 99,59%. [9]. Mayoritas penelitian-penelitian diatas menggunakan metode klasifikasi dalam pengambilan kesimpulan,

Aji Seto Arifianto adalah Dosen Jurusan Teknologi Informasi Politeknik Negeri Jember dan Mahasiswa Magister Teknik Elektro Universitas Brawijaya Malang. (email: ajiseto@gmail.com)

Moechammad Sarosa adalah Dosen Jurusan Teknik Elektro Politeknik Negeri Malang. (email: msarosa@yahoo.com)

Onny Setyawati adalah Dosen Teknik Elektro Universitas Brawijaya Malang.

seperti yang dilakukan Tabrizi untuk klasifikasi lima tipe sel darah putih terbukti pemakaian metode *Learning Vector Quantization* (LVQ) sangat memuaskan karena komputasi yang sangat ringan dan konvergensi baik[10], penelitian LVQ juga diterapkan untuk mengklasifikasikan sekumpulan data *Electrocardiogram* (ECG) penyakit *arrhythmia*. Datasets ECG *arrhythmia* terdiri dari 452 kasus dengan 279 atribut, namun 0,33% data atributnya tidak lengkap. Data dikelompokkan kedalam 16 kelas. LVQ dinyatakan lebih baik dan cepat daripada *Backpropagation* [11].


Untuk itu dalam penelitian ini diusulkan sebuah pendekatan baru untuk klasifikasi stroke secara terkomputerisasi berdasarkan data klinis pasien menggunakan metode *Learning Vector Quantization Neural Network*.

II. LEARNING VECTOR QUANTIZATION

Neural Network (jaringan saraf tiruan) termasuk salah satu metode klasifikasi yang populer. Metode ini merupakan suatu generalisasi model matematis dari cara kerja otak manusia (sistem saraf) yang didasarkan atas asumsi pemrosesan informasi terjadi pada elemen sederhana yang disebut neuron, sinyal mengalir diantara sel saraf/neuron melalui suatu sambungan dimana setiap sambungan memiliki bobot yang bersesuaian. Bobot ini akan digunakan untuk menggandakan/mengalikan sinyal yang dikirim melaluinya. Setiap sel saraf akan menerapkan fungsi aktivasi terhadap sinyal hasil penjumlahan berbobot yang masuk kepadanya untuk menentukan sinyal keluarannya. Model pembelajaran jaringan saraf tiruan memiliki 3 paradigma, yaitu: *supervised learning* artinya kumpulan masukan berusaha membentuk target luaran yang sudah diketahui sebelumnya (mengacu pada *learning data*). Perbedaan antara luaran yang masih salah dengan luaran yang diharapkan harus sekecil mungkin. Biasanya lebih baik daripada *unsupervised*. Kelemahan: pertumbuhan waktu komputasi eksponensial, data bnyk berarti semakin lambat. Kedua adalah *unsupervised learning* jika jaringan mengorganisasikan dirinya untuk membentuk vektor-vektor masukan tanpa menggunakan data atau contoh-contoh pelatihan, pada umumnya ada umpan balik. Terakhir adalah gabungan antara *unsupervised* dan *supervised*. Sedangkan berdasarkan aturan pembelajaran dalam *Neural Network* digolongkan dalam: *correlation learning* disebut juga *hebbian*, *competitive learning*, dan *feedback-based weight adaptation*[12].

Learning Vector Quantization (LVQ) termasuk jenis *Neural Network* yang dikembangkan oleh Teuvo Kohonen tahun 1989. LVQ adalah algoritma klasifikasi prototipe *supervised* dengan aturan *Competitive Learning* versi dari algoritma *Kohonen Self-Organizing Map* (SOM). Model pembelajaran LVQ dilatih secara signifikan agar lebih cepat dibandingkan algoritma lain seperti *Back Propagation Neural Network*. LVQ merupakan *single-layer net* pada lapisan masukan yang terkoneksi secara langsung dengan setiap neuron pada lapisan keluaran. Koneksi antar neuron tersebut

dihubungkan dengan bobot/*weight*. Struktur jaringan LVQ ditunjukkan pada Gambar 1, dimana x_i adalah masukan (*input*), y_i sebagai luaran (*output*) dan w_{ij} adalah bobot.



Gambar. 1. Struktur Jaringan LVQ

Neuron-neuron keluaran pada LVQ menyatakan suatu kelas atau kategori tertentu. Vektor bobot untuk suatu unit keluaran sering dinyatakan sebagai sebuah vektor referensi menggunakan klasifikasi target yang diketahui untuk setiap pola masukan. Apabila beberapa vektor masukan tersebut memiliki jarak yang sangat berdekatan, maka vektor-vektor masukan tersebut akan dikelompokkan dalam kelas yang sama. Pemilihan “vektor referensi” dengan cara kuantisasi vektor pada data learning. Secara umum algoritma LVQ sebagai berikut[13]

1. Inisialisasi vektor referensi, learning rate (α).
2. While ($stop == false$) kerjakan langkah 3-1
3. Untuk masing-masing training input, kerjakan langkah 4-9
4. Hitung J minimum dari $\|x - w_j\|$ (1)
5. Update bobot w_j dengan syarat:
6. if $T = C_j$, then
7. $w_j(\text{baru}) = w_j(\text{lama}) + \alpha[x - w_j(\text{lama})];$ (2)
8. if $T \neq C_j$, then
9. $w_j(\text{baru}) = w_j(\text{lama}) - \alpha[x - w_j(\text{lama})];$ (3)
10. Kurangi learning rate
11. Hentikan pada iterasi tertentu atau learning rate mendekati 0


Dimana,

- x = training vector (x_1, x_2, \dots, x_n)
- T = Kelas dari training vector
- w_j = bobot vektor untuk luaran ke- j
- C_j = Kategori atau kelas yang dihasilkan dari luaran ke- j
- $\|x - w_j\|$ = Jarak Euclidean antara vektor masukan dan bobot vektor ke- j

III. METODE PENELITIAN

Sistem dibangun dengan skema seperti pada Gambar 2 di bawah ini. Data yang digunakan pada penelitian ini adalah data sekunder dari dokumen rekam medis pasien rawat inap Rumah Sakit Bina Sehat dan Rumah Sakit Umum Kaliwates Jember. Data-data tersebut berisi data pemeriksaan fisik (anamnesis), data riwayat penyakit dan data hasil pemeriksaan laboratorium darah pasien. Data pasien yang diambil telah melalui pemeriksaak tim

medis dan memiliki diagnosis dokter spesialis saraf sebagai acuan dan validasi hasil klasifikasi.



Gambar. 2. Diagram Pengolahan Data

A. Karakteristik Data

Data berjumlah 373 data yang terdiri dari penderita laki-laki 52,28% dan perempuan 47,72%. Berdasarkan klasifikasi Penderita stroke *infark* sebesar 71,31% dan *hemorrhagic* 28,69% sesuai dengan literatur maupun keterangan pakar melalui wawancara langsung angka kejadian stroke *infark* di Indonesia lebih banyak dibanding stroke *hemorrhagic*. Dilihat dari usia, pasien yang pernah stroke kurang dari 45 tahun sebanyak 26 pasien, usia 45-55 tahun 105 pasien, usia 56-65 tahun 126 pasien sedangkan usia diatas 65 tahun ada 116 tahun.

B. Dataset

Dataset adalah kumpulan data yang ada dalam basisdata. Sesuai kebutuhan sistem, data dibagi menjadi dua untuk pembelajaran (*training*) jaringan saraf tiruan *learning vector quantization* dan untuk ujicoba agar tidak saling intervensi. Data yang digunakan untuk training sebanyak 323 data sedangkan untuk ujicoba 50 data. Data ujicoba harus benar-benar berbeda dari data pembelajaran untuk memenuhi aspek obyektifitas. Pembagian ini dilakukan secara acak dimana masing-masing terdiri dari data dengan klasifikasi stroke *infark* ($\pm 70\%$) dan *hemorrhagic* ($\pm 30\%$).

C. Pembelajaran LVQ

Pada tahap ini merupakan tahap dimana jaringan saraf tiruan LVQ melakukan proses “belajar” dengan sendirinya berdasarkan data pembelajaran oleh karena itu proses pembelajaran ini dikenal sebagai model terawasi (*supervised learning*).

Bobot Terbaik setelah Training:

training 32 fitur

(Waktu Training : 0.33977508544922 detik)

#	Kelas	Fitur	Nilai Bobot
1	1	HEMOGLOBIN	0.47699322380339
2	1	CHLORIDA	0.59122104449969
3	1	HDL	0.081599804408148

Gambar. 3. Bobot-bobot hasil Pembelajaran LVQ

Proses klasifikasi dengan LVQ dari dataset dicari *ideal vector* dengan mengambil nilai rata-ratanya untuk masing-masing fitur dan kelas luaran. Apabila beberapa vektor masukan tersebut memiliki jarak yang sangat

berdekatan, maka vektor-vektor masukan tersebut akan dikelompokkan dalam kelas yang sama. Dari proses pembelajaran ini akan didapatkan bobot-bobot terbaik seperti pada Gambar 3 untuk tiap hubungan antara node masukan dan luaran. Bobot-bobot ini yang akan disimpan dan digunakan dalam proses pengujian. Proses pembelajaran dibatasi dengan nilai *learning rate* atau iterasi tertentu. Jika *learning rate* mendekati nol atau iterasi telah mencapai iterasi maksimum maka proses pembelajaran dihentikan.

D. Pengujian dan Hasil Klasifikasi

Setelah mendapatkan bobot-bobot terbaik, maka untuk mengetahui keberhasilan dan performa sistem harus dilakukan pengujian. Pengujian meliputi tingkat akurasi, sensitifitas jumlah data training dan waktu. Tahap ini menggunakan dataset ujicoba. Hasil akhir dari proses klasifikasi adalah keputusan pasien menderita stroke *infark* atau *hemorrhagic*, hasil ini akan di-crosscek dengan diagnosis dokter spesialis saraf (neurology).

IV. HASIL DAN PEMBAHASAN

A. Program Aplikasi

Sistem dalam penelitian ini dikembangkan berbasis web dengan bahasa pemrograman PHP dan perangkat lunak basisdata menggunakan MySQL. Antarmuka merupakan elemen sistem yang penting karena sebagai alat komunikasi antara pengguna dan sistem. Antarmuka pertama adalah untuk melakukan inisialisasi parameter *training* seperti pada Gambar 4 diantaranya memasukkan nilai maksimum *epoch* yang digunakan untuk menghentikan program jika telah menghasilkan nilai luaran yang sama. *Learning rate* (α) adalah laju pembelajaran, semakin besar α maka semakin besar langkah pembelajaran. *Decrement α* besaran nilai yang akan digunakan untuk mengurangi nilai α agar mendekati bobot ideal. Minimum α adalah nilai terkecil dari α yang diinginkan.

Parameter Training

Max Epoch	<input type="text" value="10"/>
Learning Rate (alpha)	<input type="text" value="0.5"/>
Decrement alpha	<input type="text" value="0.01"/>
Minimum alpha	<input type="text" value="0.001"/>

nilai-nilai di atas opsional (boleh diisi atau tidak)

TRAINING LVQ

Gambar. 4. Pengisian Parameter Training

Hasil dari *training* ini adalah diperolehnya nilai bobot-bobot terbaik untuk setiap hubungan antara node masukan dan kelas luaran. Diakhir proses akan ditampilkan masing-masing bobot untuk tiap fitur masukan. Setiap pembelajaran dicatat waktu komputasinya. Ujicoba Multi Data dimaksudkan untuk

mempermudah pengujian dengan banyak data masukan sekaligus, pada percobaan kali ini data uji berjumlah 50 data. Gambar 5 merupakan hasil klasifikasi multidata. Dalam tampilan hasil klasifikasi ini ada dua kolom yaitu nilai klasifikasi yang sebenarnya berdasarkan diagnosis dokter spesialis saraf dan luaran dari sistem. Ditampilkan juga jumlah data yang benar/sesuai klasifikasinya serta yang salah.

TABEL 1
DAFTAR FITUR DAN NILAI ATAU SATUANNYA

No.	Nama Fitur	Nilai/Satuan
1	Umur	Tahun
2	Jenis Kelamin	[0].Perempuan; [1].Laki-laki
3	Sistol	mmHg
4	Distol	mmHg
5	Suhu Tubuh	⁰ Celsius
6	Denyut Nadi	x/menit
7	Pernafasan	x/menit
8	Kesadaran	[0].Tidak; [1]. Menurun
9	Mual_Muntah	[0].Tidak; [1]. Iya
10	Nyeri Kepala	[0].Tidak; [1]. Iya
11	Sulit Bicara	[0].Tidak; [1]. Iya
12	Gerak Terbatas	[0].Tidak; [1]. Iya
13	Kondisi Badan(Lemas)	[0].Tidak; [1]. Iya
14	Kejang	[0].Tidak; [1]. Iya
15	Diabetes Mellitus	[0].Tidak; [1]. Iya
16	Hipertensi	[0].Tidak; [1]. Iya
17	CVA	[0].Tidak; [1]. Iya
18	Kolesterol	[0].Tidak; [1]. Iya
19	Hemoglobin	gr/dl
20	Kadar Gula Acak	Mg/dl
21	Blood Urea Nitrogen	Mg/dl
22	Kreatinin	Mg/dl serum/plasma
23	Uric Acid	Mg/dl
24	Kolesterol Total	Mg/dl
25	Triglyceride	Mg/dl
26	High Density Cholesterol	Mg/dl
27	Low Density Cholesterol	Mg/dl
28	Natrium	mmol/L
29	Kalium	mmol/L
30	Kalsium	mg/dL
31	Chlorida	mmol/L
32	Albumin	gr/dl

(sumber: dokumen rekam medis RS.Bina Sehat dan RSU.Kaliwates Jember Jawa Timur)

B. Pengujian Akurasi

Fitur yang digunakan berdasarkan data pasien yang terdapat dalam dokumen rekam medis rumah sakit sebanyak 32 seperti pada Tabel 1. Ujicoba dilakukan dengan dua skenario yang berbeda masing-masing dengan nilai *learning rate* (α) untuk skenario 1 = 0,5 dan skenario 2 nilai $\alpha = 0,1$. Hasil akurasi klasifikasi Skenario 1 hanya 70% dan Tahap selanjutnya yaitu melakukan validasi terhadap tingkat akurasi yang dihasilkan program dengan analisis uji diagnosis. Penilaian suatu uji diagnosis akan memberikan empat kemungkinan hasil yaitu hasil positif benar, positif semu, negatif benar dan negatif semu. Keempat hasil tersebut disusun didalam sebuah Tabel 2x2 [14]. Mengacu pada Tabel 2 dihitung nilai sensitivitas, spesifitas, nilai prediksi positif dan nilai prediksi negatif. Sensitivitas adalah proporsi subyek dengan klasifikasi infark dengan hasil uji diagnosis positif

dibanding total subyek *infark*. Spesifitas adalah proporsi subyek dengan klasifikasi hemorrhagic dengan hasil uji diagnosis negatif dibanding total subyek *Hemorrhagic*.

Ujicoba dengan 32 fitur teratas.			
29	S	Infark	Infark
30	HH	Infark	Infark
31	A.S	Infark	Infark
32	K	Infark	Infark
33	A	Infark	Infark
34	SAW	Infark	Infark
35	S	Infark	Infark
36	Su	Hemorrhagic	Infark
37	W	Hemorrhagic	Infark
38	Wm	Hemorrhagic	Infark

Gambar. 5. Hasil Pengujian Klasifikasi

TABEL 2
UJI DIAGNOSIS SKENARIO 1

		Diagnosis Dokter		
		Inf	Hemo	Jumlah
Hasil	Inf	35	15	50
Program	Hemo	0	0	0
	Jumlah	35	15	50

Keterangan: Inf = Stroke *infark*; Hemo = Stroke *hemorrhagic*


Nilai-nilai sensitifitas dan spesifisitas tersebut digambarkan dalam kurva *Receiver Operating Characteristic* (ROC) [15] seperti ditunjukkan Gambar 6. Untuk menilai tingkat keberhasilan diagnosis yang dihasilkan program dilihat dari Nilai *Area Under Curve* (AUC) sebesar 0,5, hal ini berarti bahwa pengujian tergolong dalam kondisi gagal (fail/F) dan tidak dapat dijadikan sebagai alat bantu diagnosis stroke.

$$\text{Sensitivitas} = \frac{35}{(35 + 0)} \times 100\% = 1 (100\%)$$

$$\text{Spesifisitas} = \frac{0}{(0 + 15)} \times 100\% = 0 (0\%)$$

$$\text{Nilai prediksi positif} = \frac{35}{(35 + 15)} \times 100\% = 0,7 (70\%)$$

$$\text{Nilai prediksi negatif} = \frac{0}{(0 + 0)} \times 100\% = -$$



Gambar. 6. ROC Ujicoba Skenario 1

Sedangkan hasil ujicoba skenario 2 akurasi sebesar 96%, lebih rinci dapat dilihat pada Tabel 3. Berdasarkan Tabel 3 seperti pada skenario 1 selanjutnya

dihitung nilai sensitivitas, spesifisitas, nilai prediksi positif dan nilai prediksi negatif. Nilai-nilai sensitifitas dan spesifisitas tersebut digambarkan dalam kurva *Receiver Operating Characteristic* (ROC) seperti ditunjukkan Gambar 7.

TABLE 3
UJI DIAGNOSIS SKENARIO 2

Diagnosis Dokter				
Hasil Program	Inf Hemo	Inf	Hemo	Jumlah
		34	1	35
		1	14	15
	Jumlah	35	15	50

Keterangan: Inf = Stroke *infark*; Hemo = Stroke *hemorrhagic*


Sensitivitas = $34 / (34 + 1) \times 100\%$
= 0,971 (97,1%)

Spesifisitas = $14 / (1 + 14) \times 100\%$
= 0,933 (93,3%)

Nilai prediksi positif = $35 / (34 + 1) \times 100\%$
= 0,971 (97,1%)

Nilai prediksi negatif = $14 / (14 + 1) \times 100\%$
= 0,933 (93,3%)

Sekali lagi untuk menilai tingkat keberhasilan diagnosis yang dihasilkan program dilihat dari *Nilai Area Under Curve* (AUC) dan dari perbandingan skenario 2 diperoleh hasil yang lebih baik yaitu sebesar 0,952, hal ini berarti bahwa pengujian tergolong dalam kondisi sangat baik (*excellent/A*).



Gambar. 7. ROC Uji coba Skenario 2


C. Pengujian Data Training

Data *training* dalam penelitian ini digunakan untuk proses pembelajaran *Learning Vector Quantization* hingga mendapatkan bobot-bobot terbaik. Didalam data *training* terdapat hasil diagnosis dokter sebagai target untuk melatih jaringan LVQ yang bersifat *supervised*. Percobaan ini dilakukan dengan jumlah data berbeda-beda, mulai 100 data, 150 data, 200 data, 250 dan 323 data yang dipilih secara acak. Hal ini untuk mengetahui pengaruh jumlah data *training* terhadap waktu pembelajaran/*training* klasifikasi. Waktu *training* dihitung dari awal inisialisasi bobot, proses perbaikan bobot hingga mendapatkan bobot-bobot terbaik. Hasil pengujian waktu disajikan dalam Tabel 4. Perbedaan waktu training untuk 2 skenario divisualisasikan dalam

bentuk grafik seperti pada Gambar 7 dibawah ini. Semakin banyak jumlah data *training* maka semakin banyak pula waktu yang dibutuhkan. Hal ini dapat diartikan jika keterbatasan jumlah data tidak menjadi kendala bagi proses pembelajaran LVQ.

TABEL 4
WAKTU TRAINING (DETIK)

Jumlah Data Training	Skenario 1	Skenario 2
100_a	0,09375	0,0957
100_b	0,094533	0,094487
100_c	0,097811	0,09413
150	0,145324	0,144826
200	0,1991	0,191964
250	0,241385	0,236768
323	0,318657	0,31022



Gambar. 7. Grafik Uji Waktu Training

V. KESIMPULAN

Berdasarkan uraian permasalahan hingga hasil penelitian, maka dapat disimpulkan beberapa hal sebagai berikut:

1. Sistem yang dibangun berhasil mengklasifikasi stroke berdasarkan kelainan patologi dengan tingkat akurasi 96% dengan nilai AUC termasuk dalam kategori *excellent* (A).
2. Metode *Learning Vector Quantization* ternyata mampu melakukan klasifikasi dengan akurasi tinggi hanya dengan 100 data *training*. Hal ini sebuah indikasi baik jika disuatu wilayah kasus pasien stroke belum banyak maka dengan keterbatasan data tetap bisa dijadikan sebagai data *training*.

REFERENSI

- [1] Yayan A. Israr, *Stroke*, Fakultas Kesehatan Universitas Riau. Pekanbaru, 2008.
- [2] Ekowati Rahajeng, *Upaya Pengendalian Penyakit Tidak Menular Di Indonesia*, Buletin Penyakit Tidak Menular, ISSN 2088-270X, Semester II 2012, pp.23-28, Jakarta, 2011.
- [3] Mochammad Bahrudin, *Model Diagnostik Stroke Berdasarkan Gejala Klinis*, Jurnal Sainika Medika Vol.6 No.13 Universitas Muhammadiyah, Malang, 2010.
- [4] Andreas C Widjaja, *Tesis. Uji Diagnostik Pemeriksaan Kadar D-Dimer Plasma Pada Diagnosis Stroke Iskemik*, Patologi Klinik Fakultas Kedokteran Universitas Diponegoro, Semarang, 2010.

- [5] Mochammad Bahrudin, *Diagnosa Stroke*. Jurnal Saintika Medika Vol.5 No.11 Universitas Muhammadiyah, Malang, 2009.
- [6] Irahman, A. Abde., Omer H., *Breast Ultrasound Images Enhancement Using Gray Level Co-Occurrence Matrices Quantizing Technique*, International Journal of Information Science 2012, 2(5).2012, pp.60-64.
- [7] Rahmadwati, *Computer Aided Diagnostic Support System (CADSS) For Cervical Cancer Classification*, University Of Walonggong, Australia, 2012
- [8] Ipin Prasoj, S. Kusumadewi, *Diagnosis EKG dengan Sistem Pakar menggunakan K-NN*. Magister Universitas Islam Indonesia, Jogjakarta, 2013.
- [9] Duen-Yian Yeh., Ching-Hsue Cheng., Yen-Wen Chen, *A Predictive Model For Cerebrovascular Disease Using Data Mining*, Expert Systems with Applications International Journal, Elsevier, 2011.
- [10] P. R. Tabrizi., S. H. Rezatofighi., M. J. Yazdanpanah, *Using PCA and LVQ Neural Network for Automatic Recognition of Five Types of White Blood Cells*, International Conference of the IEEE EMBS, Buenos Aires Argentina, 2010.
- [11] Alaa M. Elsayad, *Classification of ECG arrhythmia Using Learning Vector Quantization Neural Networks*, IEEE, 2009.
- [12] Kishan Mehrotra., Chilukuri K.M., Sanjay R, *Elements of Artificial Neural Networks*, A Bradford Book, 1996.
- [13] Laurene Fausett, *Fundamentals Of Neural Networks. Architectures, Algorithms, And Applications*, New Jersey: Prentice-Hall, Inc, 1994.
- [14] Sastroasmoro, S., Sofyan Ismael., *Dasar – Dasar Metodologi Penelitian Klinis*, Jakarta : Binarupa Aksara, 1995.
- [15] John Eng, MD., *Receiver Operating Characteristic Analysis: A Primer I*, Academic Radiology, Vol 12, No 7, July, 2005.